

Análisis comprensivo de YASA para la caracterización del sueño

Linares, Gonzalo Ezequiel
I.T.B.A.
Buenos Aires, Argentina
golinars@itba.edu.ar

Bustelo, Nicolás
I.T.B.A.
Buenos Aires, Argentina
nbustelo@itba.edu.ar

Sergi, Ezequiel Damián
I.T.B.A.
Buenos Aires, Argentina
dsergi@itba.edu.ar

Gullino, Agustín Luis
I.T.B.A.
Chubut, Argentina
agullino@itba.edu.ar

Felman, Santiago
I.T.B.A.
Mendoza, Argentina
sfeldman@itba.edu.ar

Abstract—A medida que avanza la tecnología, contamos con nuevas tecnologías para dar explicación a fenómenos naturales que antes no podíamos explicar. Uno de los campos con menos explicaciones en el área de la medicina es la neurociencia. Particularmente, el sueño es un fenómeno transversal a todos los seres vivos. Para poder extraer información de las señales de la corteza cerebral y músculos, se requiere un exhaustivo tratamiento de las señales. Un estudio de interés para la ciencia es el *scoring* del sueño. Dado que implementar un sistema de detección de fases del sueño es un trabajo arduo, que requiere profesionales de múltiples disciplinas, se suelen buscar alternativas mas eficientes. Para realizar el *scoring* de señales de sueño se tendrá en cuenta la biblioteca YASA, los algoritmos involucrados y la implementación de dicha biblioteca para la investigación de las distintas etapas de sueño.

Index Terms—Análisis de datos, Machine Learning, Deep Learning, Modelos equivalentes, Modelado y recuperación de atributos físicos, *Sleep Scoring*, Polisomnografía, Short Time Fourier Transform, Procesamiento de señales, Feature Engineering.

I. INTRODUCCIÓN

Desde el siglo XIX que es conocida la presencia de señales eléctricas en el cerebro de humanos. Pasaron muchos años hasta que se desarrollara la tecnología necesaria para poder analizar estas señales circundantes en el cerebro y poder establecer una teoría que las relacione para extraer información útil, que tenga el propósito de ayudar tratar enfermedades y dar explicaciones del funcionamiento del cerebro humano.

Hoy en día la electroencefalografía, conocido en la jerga como EEG, es ampliamente utilizada en el diagnóstico y tratamiento de enfermedades como la epilepsia y las apneas del sueño, siendo también un campo de pleno desarrollo en donde frecuentemente se encuentran nuevos usos y funciones para estas mediciones.

En este informe nos centraremos en las señales de EEG para el análisis del sueño. Es usual que para ellos, se utilicen señales provenientes de varios electrodos distribuidos en la superficie del cráneo. Para complementar las mediciones del EEG, se requiere información adicional para corroborar lo que se mide en el cerebro. Algunas de estas mediciones

son, por ejemplo, los electrooculogramas (EOG) que detectan el movimiento de los ojos, electrocardiogramas (ECG) para ver la actividad del corazón y electromiogramas (EMG) que detectan el movimiento de los músculos. El conjunto de todas estas mediciones durante el sueño es llamado polisomnografía (PSG). No existen reglamentaciones específicas acerca de las medidas que deben llevarse a cabo en cada estudio, sin embargo la American Academy of Sleep Medicine (ASSM) otorga ciertas recomendaciones útiles para estandarizar el proceso. En la Figura 1 puede observarse una imagen de un hombre recostado en una cama, el cual se le esta realizando un estudio de sueño haciendo uso de un polisomnógrafo portátil.



Fig. 1. Hombre realizándose un estudio de sueño mediante un polisomnógrafo portátil

II. CARACTERÍSTICAS DEL SUEÑO

El sueño es un complejo proceso biológico, el cual es necesario y esencial para la vida de la mayoría de los seres vivos del planeta. Es un fenómeno altamente estudiado y es evidente su importancia en la salud humana, ya que mejora el ánimo, repara los músculos dañados, mantiene las funciones críticas del cuerpo estables y permite el procesamiento de la información adquirida en el día. [2]

El sueño consta de dos fases principales: la fase REM o “*Rapid Eye Movement*” y la fase NREM o “*No REM*”. La fase NREM a su vez se divide en 4 etapas y cada una tiene sus particularidades:

- Etapa I: Transición de despierto a dormido. Representa del 5% al 10% del total dormido.
- Etapa II: Donde la persona se encuentra dormida generalmente. Representa del 40% al 50%.
- Etapa III y IV: Muy similares entre sí (por lo que muchas veces se omite su diferenciación) y corresponden a la etapa de sueño profundo.

Generalizando, todas las etapas de sueño NREM se caracterizan por amplitudes de señal crecientes a medida que aumentamos la etapa en sentido N1 a N4 y frecuencias descendentes nuevamente en sentido N1 a N4, siendo la señal en N1 la mas parecida a vigilia en cuanto a frecuencia y amplitud respecta.

La etapa REM representa del 20 al 25% del total del sueño y junto al NREM (N2) tienen la función de guardar las memorias de corto plazo en la corteza cerebral, por lo cual son parte fundamental de la formación de recuerdos y del aprendizaje. La etapa de REM ocurre varias veces en una sesión prolongada de 8 horas y aparece por primera vez entre los 70 y 90 minutos después de dormirse con una duración promedio de 45 minutos. Como su nombre lo indica, es donde se observan movimiento en los ojos y es la fase las señales de EEG se asemejan a una persona en vigilia.

La falta de sueño causa problemas como perdida de memoria, rendimiento mental reducido o dificultades en la concentración. Si la falta se agrava podemos llegar a los casos más extremos como alucinaciones o trastornos de personalidad.

En la Argentina casi un 76% de las personas presentan una alteración de sueño, el 38,61% presenta insomnio o sueño interrumpido y el 21,39% duerme menos de las ocho horas recomendadas según informa una reciente encuesta el Observatorio de Psicología Social Aplicada de la Facultad de Psicología de la Universidad de Buenos Aires (UBA). [3]

Por todo lo mencionado anteriormente, es que resulta muy importante estudiar el sueño, sus etapas y como mantener una buena higiene de sueño, para así mejorar significativamente la calidad de vida las personas, deterioradas por el estrés y la tecnología de la vida contemporánea.

III. MEDICIÓN E INTERPRETACIÓN DE UN EEG

Si se quiere entender que es lo que se está midiendo en un electroencefalograma se debe tener un mínimo conocimiento de las señales eléctricas que suceden dentro de la cabeza de un ser humano. El cerebro está compuesto por alrededor de 10^{11} neuronas, las cuales están formadas por un cuerpo celular, un gran número de pequeñas prolongaciones llamadas dendritas y una prolongación principal que puede ser muy larga y recibe el nombre de axón, el cual a su vez puede ramificarse en muchas ramas al final de su recorrido. El funcionamiento de las mismas es complejo. A grandes rasgos, las dendritas reciben pequeños pulsos eléctricos del sistema nervioso central dados por estímulos externos o sinapsis con otras neuronas. El cuerpo

celular de la neurona puede transformar esta información a una variación de potencial dada por un intercambio de iones en su composición, que resulta en una corriente transmitida por el axón hacia otras neuronas lo cual conforma una altamente compleja red de conexiones neuronales.




Fig. 2. Estructura de una neurona.

Al activarse estas células cerebrales el conjunto de corrientes circulantes por cada axón generan un campo magnético y en consecuencia un campo eléctrico secundario. La medición de este último, que no considera una única neurona sino el de muchas en conjunto, es lo que conforma la señal de un EEG.

Si bien la variación de potencial de la membrana se encuentra cerca de los $60mV$, dadas la impedancia del cuero cabelludo, el cráneo y el cerebro se precisan de un conjunto grande de neuronas para lograr que algo de esta actividad sea perceptible, y aún así las mediciones del EEG se encuentran entre $10\mu V$ y $100\mu V$, lo cual siendo tan pequeñas causarían un problema para el preprocesamiento de las señales.

Respecto de las mediciones de EEG, se las suele subdividir en diferentes bandas de frecuencia para su análisis llamadas ondas o ritmos cerebrales. Esta subdivisión en general varía según su aplicación; para el caso del sueño consta de las bandas de la Tabla I.

TABLE I
RITMOS CEREBRALES NORMALES Y SUS FRECUENCIAS ASOCIADAS.

Ritmo	Símbolo	Frecuencia [Hz]
Delta	δ	0,5-4
Theta	θ	4-7,5
Alfa	α	8-13
Beta	β	14-26
Gamma	γ	30-45

Las ondas δ , que son las de menor frecuencia, son las presentes en el sueño profundo. Las θ aparecen en el pasaje de consciencia a somnolencia y se asocian a un estado de meditación profunda. Las ondas α tienen una forma sinusoidal, una amplitud por debajo de los $50\mu V$ e indican un estado de consciencia con falta de atención o concentración. Las β poseen una amplitud por debajo de los $30\mu V$ y se las asocia con el pensamiento activo, la atención y la resolución de problemas concretos. Las ondas γ son de una amplitud muy pequeña y su detección es usada para confirmar ciertas enfermedades cerebrales.




Fig. 3. Gráficos temporales de los cuatro ritmos cerebrales descriptos

También existen ciertas ocurrencias temporales asociables a cada una de las etapas del sueño, como los Spindles - ráfagas de 11 a 15 Hz de corta duración - o los complejos K - ondas de amplitud elevada y lentas.

IV. PREPROCESAMIENTO DE SEÑALES DE EEG

En un principio, los EEG eran directamente conectados a un sistema de escritura, quedando grabadas en tinta y papel las variaciones de potencial dadas en cada electrodo. Como uno puede imaginarse, era muy complicado entonces hacer largas grabaciones de datos que luego puedan analizarse fácilmente, era claro que hacía falta digitalizar tales grabaciones.

Hoy en día, los EEG consisten de un set de electrodos muy delicados cada uno con su respectivo amplificador diferencial y conversor analógico digital, tal que luego de pasar por algunos filtros la lectura quede útil para su registro.

Afortunadamente el ancho de banda efectivo de las señales EEG es aproximadamente 100Hz lo cual permite que la frecuencia de muestreo sea muy accesible en 200Hz cumpliendo el criterio de Nyquist. Por otro lado, suelen utilizarse 16bits para representar cada una de las mediciones, lo cual hace que estas sean muy pesadas y las grabaciones totales terminen siendo masivas, lo cual con las tecnologías actuales no representa un gran problema, aunque si puede ser molesto.

Respecto al condicionamiento de la señal, además de los filtros anti alias, se utilizan otros filtros para remover componentes indeseados de las señales. Para empezar, un filtro pasa altos con frecuencia de corte muy baja es normalmente utilizado para remover componentes molestos de baja frecuencia como los de respiración. También suele utilizarse un filtro notch para eliminar el componente de 50Hz debido a la alimentación de la señal, y un filtro pasa bajos con frecuencia de corte variable si se quiere eliminar los componentes de la señal de mayor frecuencia.

En el condicionamiento del EEG es donde entran algunas de los otros parámetros de las polisomnografías nombrados anteriormente. Esto se debe a que el movimiento del cuerpo en general produce señales en el cerebro que enmascaran los ritmos cerebrales que quieren analizarse. Un ejemplo de esto

es el parpadeo de los ojos, por lo cual se toman mediciones de electrooculograma. Lo mismo sucede con la contracción de los músculos, lo cual se puede resolver con el electromiograma.

V. PRINCIPIOS BÁSICOS DEL PROCESAMIENTO DE EEG

Para empezar la señal no es analizada como un único tramo de 8 horas, si no que se divide en pequeños segmentos, llamados “épocas”. Esto se debe a que la señal en si no es estacionaria, pero puede suponerse cuasi-estacionaria en pequeños intervalos y en consecuencia inferir que para ellos las características en tiempo y frecuencia son similares. Esto permite, por ejemplo, el uso de herramientas como la FFT.

Por otro lado las señales de EEG de varios canales se suelen considerar como gaussianas multivariantes, cuya media y covarianza varía en función del tiempo pero se mantiene constante en pequeños intervalos (en lo previamente llamado épocas). Es de utilidad entonces para el entendimiento de cada época la estimación de ciertos parámetros típicos de procesos gaussianos, como pueden ser la media, covarianza, Kurtosis, Skewness, etc. Estos serán presentados más adelante en el texto.

El método dominante actual para el procesamiento de señales EEG y el cual se analizará principalmente en este informe es con el uso de *deep learning*. Existen también otras herramientas para el análisis, que se complementan con la previamente nombrada. Ejemplos de esta son el uso de modelos de predicción lineales, y el intento de modelado físico del sistema cerebral, el cual es complicado debido a las alinealidades de su comportamiento.

VI. YASA: YET ANOTHER SPINDLE ALGORITHM

A. Introducción

Hasta hace un par de años, el análisis de las polisomnografías se realizaba de forma manual. Luego del preprocesamiento de las señales, identificar las etapas del sueño era una tarea que realizaban personas entrenadas. Este proceso presentaba una serie de problemas. Principalmente, consumía mucho tiempo: la identificación de las etapas del sueño en un EEG, con duración de 4 a 12 horas, tomaba por lo menos 2 horas. Además, se tenía un cuello de botella práctico, ya que se contaba con miles de horas de sueño grabadas por noche y muy poca gente capacitada para analizarlas. Asimismo, distintas personas entrenadas para realizar este análisis obtenían diferentes resultados para una misma época. Un estudio muestra que la concordancia máxima entre distintas personas analizando la misma época es del 85%.

Con el advenimiento del *machine learning*, se comenzaron a implementar algoritmos que permitían identificar las distintas etapas del sueño y clasificarlas de manera mucho más precisa y más rápidamente. El inconveniente con muchas de estos algoritmos es que se encuentran detrás de un *paywall* (o, en su defecto, utilizan software de pago) o son muy inaccesibles al momento de ser utilizados por médicos o en laboratorios. Además, muchos de estos algoritmos eran algoritmos de caja negra; es decir, no se conocía su funcionamiento interno, lo que los hacía menos confiables a la hora de ser implementados.

Debido a los problemas presentados, surge la necesidad de una herramienta como YASA (Yet Another Spindle Algorithm): una biblioteca de Python libre y gratuita cuya red neuronal fue exhaustivamente entrenada con una gran variedad de datos (gente con diferentes patologías o enfermedades, como apnea del sueño o Alzheimer, y gente que tenía un sueño de calidad). YASA realiza estudios de polisomnografías de manera completamente automatizada y con un nivel de precisión de hasta el 95%.

YASA permite detectar distintas características de las etapas REM y NREM del sueño, como por ejemplo Spindles Y SWS. También, permite realizar un análisis espectral de las señales utilizando la STFT (Short Time Fourier Transform) y analizar la potencia de cada etapa. Finalmente, se pueden producir gráficos muy útiles como hipnogramas: gráficos que muestran las distintas etapas del sueño para distintos tiempos.

B. Mediciones de polisomnografía requeridas

Como ya se menciono, las polisomnografías no incluyen mediciones estandarizadas, en general se incluyen varios canales de EEG, EMG de músculo mandibular, EOG de ambos o uno de los ojos, y ECG. Por este motivo, la cantidad de datos y mediciones puede variar entre clínica y clínica, por lo que los desarrolladores de YASA tomaron la decisión de centrar su análisis utilizando mediciones de EEG de la zona central, EOG de ojo izquierdo y EMG de mandíbula.

Con esto en cuenta, construyeron herramientas con la capacidad de analizar desde un único EEG hasta la combinación de todas las mediciones mencionadas, pero siempre se requiere como mínimo una medición de EEG [4]. Es importante tener en cuenta que esto también afecta a la precisión que tienen las herramientas, ya que cuentan con una cantidad de datos limitada la polisomnografía. Es importante aclarar que las mediciones deben estar almacenadas en unidades estándar (μV).

C. Preprocesamiento y extracción de Features

Antes de la extracción de *Features*, se realiza un preprocesamiento básico. En primer lugar un remuestreo para llegar a $100Hz$, y luego se pasa por un filtro pasa-banda entre $0.4Hz$ y $30Hz$, y esto se realiza con todas las señales, sean EEG, EMG o EOG. Con esto la señal esta lista para la extracción de características. A continuación se explicaran en distintas secciones las *Features* utilizadas para la clasificación. YASA identifico estas características de otros trabajos de investigación donde se buscaron las mejores *Features* para el *Sleep Scoring*.

1) *Momentos y propiedades estadísticas*: El desvío estándar (momento de segundo orden) se utiliza como métrica de la energía de la señal a analizar. El rango intercuartil por otro lado, al ser la diferencia entre el tercer y primer cuartil de la distribución representa la dispersión de los valores obtenidos y da un intervalo centrado de ubicación del 50% de los datos.

Por otra parte, el parámetro de *skewness* permite conocer la simetría de la distribución y el de *Kurtosis* la forma que la misma tiene. Estos parámetros, además de proveer información

valiosa acerca de la distribución estadística permiten saber que tanto se acerca a un proceso gaussiano la distribución encontrada.

2) *Densidades y relaciones de potencia espectral*: YASA utiliza información del dominio en frecuencia tomando distintas mediciones de potencia espectral. En primer lugar toma la potencia total en la banda de $0.4Hz$ a $30Hz$, y luego calcula las potencias contenidas en las bandas de frecuencia conocidas presentes en el cerebro: Delta 1, $0.4Hz - 1Hz$; Delta 2, $1Hz - 4Hz$; Tita, $4Hz - 8Hz$; Alfa, $8Hz - 12Hz$; Sigma, $12Hz - 16Hz$; Beta, $16Hz - 30Hz$. Además, en estudios previos se encontró que la relación de potencias en estas bandas mejora la capacidad predictiva de los modelos, por lo que se incluye también relaciones espectrales como $\frac{Delta}{Beta}$, $\frac{Tita}{Alfa}$, entre otras. Esto solo se utiliza en las señales de EEG y EOG ya que en los EMG y ECG no tiene sentido buscar estas bandas. De todas formas se utiliza un análisis en frecuencia similar.

3) *Movilidad y Complejidad de Hjorth*: Estas métricas son muy utilizadas en el análisis de EEG [5], ya que corresponden a las relaciones de distintos momentos estadísticos de la potencia espectral, y por lo tanto permiten otra caracterización de la señal. En el caso de la movilidad esta caracteriza el desvío estándar de la potencia espectral, relacionándose con la derivada de la señal. Esto se ve en la expresión que la define:

$$Movilidad = \sqrt{\frac{var\left(\frac{dy(y)}{dt}\right)}{var(y(t))}}$$

En esta expresión se tiene una función arbitraria $y(t)$, y relaciona la varianza de su derivada con su varianza. Se puede interpretar como una medición de la cantidad de cambio que percibe la señal. Una derivada de alta varianza implica que en todo instante tiene cambios mas bruscos, y si se junta con una varianza de señal baja, implica que en un rango acotado de señal esta cambió su derivada varias veces. Por ejemplo un Spindle, como fue definido en la Sección III, es una señal de alta movilidad.

En el caso de la Complejidad, esta relaciona los momentos del espectro de cuarto, segundo y cero orden, y en el tiempo se corresponde con las relaciones de movilidad de la derivada y la señal:

$$Complejidad = \frac{movilidad\left(\frac{dy(t)}{dt}\right)}{movilidad(y(t))}$$

En este caso, esta métrica caracteriza la distribución espectral de la señal siendo mayor cuanto mas dispersa la energía en el espectro. Por ejemplo, una señal senoidal tiene una complejidad de 1, que es el valor mínimo posible de complejidad.

4) *Entropía de permutación*: Esta es otra medición para caracterizar la complejidad de una señal. Este método permite caracterizar que frecuencias dominan en la densidad de potencia espectral. Si el proceso es dominado por altas frecuencias, este parámetro se maximiza, acercándose a 1. En caso de bajas frecuencias ocurre lo contrario, y el parámetro tiende

a 0. Esta medida se puede obtener calculando la entropía de Shanon de la distribución de posibles permutaciones de un grupo acotado de mediciones. Estos grupos se pueden construir con D cantidad de mediciones con un intervalo arbitrario entre ellas y entre cada grupo. Para ese grupo de D miembros, se toma solamente su ordinalidad numérica ($a < b < c$) y ese grupo se asigna a una de las $D!$ permutaciones que corresponden a las posibles formas de ordenar D números distintos. Por ejemplo, el grupo $[3, 1, 2]$ corresponde a la permutación $\{2, 0, 1\}$, y el grupo $[7, 100, 1]$ se corresponde con $\{1, 2, 0\}$. La distribución de las permutaciones se obtiene de las frecuencias de aparición relativa de cada grupo. De esta forma, se obtiene otra vista de la complejidad temporal de la señal, y por lo tanto sus características espectrales.

5) *Dimensión fractal*: Al igual que las *Features* anteriores, esta es otra caracterización de la complejidad temporal de una señal. Esta se corresponde a la complejidad que se ve de una señal a medida que se cambia la escala de representación. Un problema común que describe esta característica es el análisis de las líneas de la costa marítima. En una escala de, por ejemplo, 10km las líneas tienen un detalle y curvatura particular dado. Al momento de achicar esa escala, la forma de la línea de costa se vuelve mucho mas detallada, o en otras palabras, compleja. Se puede demostrar que existe una relación que define este aumento de la complejidad (el perímetro por ejemplo) en función de la escala, y se conoce como:

$$N = \epsilon^{-D}$$

Donde ϵ define el factor de escalamiento, y N la nueva medida de complejidad(perímetro normalizado para este caso). En esta expresión, D se corresponde con la dimensión fractal. El ejemplo descrito se relaciona con la interpretación geométrica de la dimensión fractal, pero demuestra la utilidad de esta caracterización. En pocas palabras, se mide como aumenta la cantidad de detalle o complejidad que tiene una señal a medida que se disminuye la escala donde se observa. Existen diversos métodos para estimar la dimensión fractal de una señal, y en el caso de YASA se utiliza el de Higuchi y el de Petrosian. Una explicación y análisis de estos algoritmos junto con otros se puede encontrar en [6].

6) *Cantidad de cruces por cero*: En estudios previos se demostró que esta métrica aporta información relevante para la caracterización del sueño.

7) *Suavizado y normalización*: En el *Sleep Scoring* manual siempre se tienen en cuenta los periodos anteriores y posteriores para la catalogación. Esto tiene sentido, ya que si se quiere catalogar una sección de características similares a futuro y pasado, es mucho mas probable que la categoría de sueño permanezca constante. Por este motivo, YASA utiliza las *Features* obtenidas, y realiza un suavizado utilizando una ventana pesada triangular centrada, con 15 valores de ancho. En otras palabras una media móvil ponderada donde la muestra actual tiene peso 1 y las anteriores y futuras tienen un peso decreciente a medida que se alejan temporalmente hasta alcanzar el ancho de 15 muestras. Además de esta media móvil, también se hace una media ponderada móvil pero solo

de los 3 valores anteriores y el actual para que en caso de un periodo largo de estabilidad, esta información proporcione el peso estadístico para mantener la categoría. Ambos suavizados son luego normalizados de acuerdo al rango intercuantil.

D. Técnica de Machine Learning utilizada

Una vez obtenidas las *Features*, estas se utilizan en un modelo creado con LightGBM (<https://github.com/microsoft/LightGBM>). Este Framework de código abierto creado por Microsoft permite implementar un árbol de decisión entrenado a través de *Gradient Boosting*. Un árbol de decisión es una técnica de aprendizaje profundo utilizada en regresión y clasificación con el uso de los llamados *weak learners*. Un *Weak Learner* es un modelo predictor simple que luego de ser entrenado es levemente mejor que dar una respuesta de forma aleatoria. Un ejemplo básico de este modelo es un regresor lineal simple. Un árbol de decisión se basa en el uso de estos modelos donde cada uno de ellos aprende una regla de decisión básica a través del entrenamiento, y esto le permite aumentar la complejidad agregando cada vez mas modelos.

El texto anterior describe de forma general la estructura del modelo final, pero en ultima instancia, se trata de un bloque F que dadas las entradas, genera una predicción (probabilidad o valor) de salida. Para poder entrenar el modelo, se debe definir una función de pérdida, que dada la predicción y los valores verdaderos (*Ground Truth*) permita minimizar ese error. Esta función de pérdida depende de los valores verdaderos y de la predicción, y por ende de los parámetros de los *Weak Learners* y las entradas. Para poder corregir los parámetros y entrenar el modelos, es un requerimiento que esta función de perdida sea continua, ya que el método de entrenamiento se basa en el descenso por gradiente.

En particular este tipo de modelos son bastante utilizados en el ámbito del *Sleep Scoring* siendo rápidos y con un buen nivel de precisión, pero existe una gran variedad de estructuras y modelos que podrían alcanzar un resultado mejor.

E. Pruebas

Utilizando una polisomnografía de noche completa que incluye EEG, ECG, EOG y EMG entre otras cosas, se intento utilizar la biblioteca YASA para predicción y análisis de sueño. En la Figura 4 se puede observar la comparación entre la predicción y el *Scoring* de las anotaciones de los datos. Podemos observar que en las zonas de estabilidad YASA funciona muy bien mientras que en las transiciones tiende a oscilar entre estados. Tambien se hace evidente la dificultad de detección de estado N2 y N1, viendo que confunde ambos en varios casos. Para discernir mejor los errores cometidos se puede observar la matriz de confusión en la Figura 5 donde se aprecia que se marcaron varias secciones como N1 siendo estas N2.




Fig. 4. Resultado de Sleep Scoring utilizando EEG, EOG y EMG.




Fig. 5. Matriz de confusión del Sleep Scoring mostrado en la Figura 4.

Por otro lado, también se realizaron pruebas quitando de a un canal extra por vez, comenzando con el ejemplo mostrado (EEG, EOG y EMG) y finalizando con predicción solo con EEG. Los resultados de este proceso se encuentran en la Tabla II, donde podemos ver que el agregado del EMG no genera una diferencia significativa pero el EOG da un 10% de coincidencia mas.

	EEG-EOG-EMG	EEG-EOG	EEG
Coincidencia [%]	83.5	82.9	72.1

TABLE II

RESULTADO DE 3 Sleep scorings CADA UNO CON CADA VEZ MAS CANALES DE MEDICIÓN.

En la Figura 6 se puede apreciar el problema de no agregar el EOG. En primer lugar la etapa de REM parece ser confundida con mas frecuencia, y en general se observa que se reducen las confusiones. Un motivo probable es que al agregar el EOG permite al modelo identificar las posibles interferencias del EOG en el EEG, ya que este es un problema comun debido a la cercanía de los tejidos.




Fig. 6. Matriz de confusión del Sleep Scoring utilizando solamente la señal de EEG.

VII. CONCLUSIÓN

En este trabajo de investigación se ha analizado gran parte de todo el proceso de análisis de sueño, hablando desde la necesidad biológica hasta la caracterización de las señales que permiten estudiarlo. Ha quedado también completamente probada la necesidad de sistemas digitales desde el registro de las señales hasta su posterior análisis.

Por otro lado, YASA representa un verdadero antes y después en la cronología del análisis de sueño debido a la facilidad de acceso del público a su utilización y la precisión con la que permite diagnosticar. La misma permite obtener con facilidad a través del uso de algoritmos de *machine learning* muchos parámetros importantes, como los anteriormente descritos, directamente correlacionados con la salud del sueño.

Para finalizar, se puede concluir que este trabajo de investigación fue una excelente oportunidad para tratar un tema práctico relacionado con el procesamiento de señales.

REFERENCES

- [1] Saeid Sanei, and J.A. Chambers. "EEG Signal Processing" Wiley-Interscience; 1ra edición, Septiembre 2007.
- [2] "Get Enough Sleep". <https://health.gov/myhealthfinder/healthy-living/mental-health-and-relationships/get-enough-sleep>. Julio 2022.
- [3] "Relevamiento del estado psicológico de la población Argentina". https://www.psi.uba.ar/opsa/informes/opsa_salud_mental_poblacion_argentina_2022.pdf, Diciembre 2022.
- [4] Raphael Vallat, Matthew P Walker (2021) An open-source, high-performance tool for automated sleep staging eLife 10:e70092. <https://doi.org/10.7554/eLife.70092>
- [5] Bo Hjorth, "EEG analysis based on time domain properties", Electroencephalography and Clinical Neurophysiology, Volume 29, Issue 3, 1970, Pages 306-310, ISSN 0013-4694,
- [6] R. Esteller, G. Vachtsevanos, J. Echaz and B. Litt, "A comparison of waveform fractal dimension algorithms," in IEEE Transactions on Circuits and Systems I: Fundamental Theory and Applications, vol. 48, no. 2, pp. 177-183, Feb. 2001, doi: 10.1109/81.904882.